

MP 5149 · UT5 · INTRODUCCIÓ A LES XARXES NEURONALS SUPERVISADES

Del perceptró al perceptró multicapa

Com funciona una neurona artificial, per què una sola no basta, i com una xarxa aprèn a construir ella mateixa les característiques que necessita.

Dos mòduls en paral·lel, dues famílies d'algorismes

MP 5134

Algorismes clàssics

Disseny i avaluació de models

Regressió lineal i logística, k-nearest neighbors, decision trees, random forest, SVM, k-means.

Cada algorisme és **una idea concreta** sobre com separar o ajustar les dades. Els feu servir amb scikit-learn i us centreu a **avaluar-los**.

MP 5149

Xarxes neuronals


Desenvolupament de components software

Perceptró, perceptró multicapa, mapes autoorganitzatius, xarxes de Hopfield.

Totes es construeixen igual: **moltes neurones molt simples, totes iguals, connectades en capes**. Cap neurona sola fa gran cosa; la potència ve de connectar-ne moltes.

Als dos mòduls es treballa igual: amb scikit-learn, qualsevol model s'entrena amb `fit` i fa prediccions amb `predict`. Aquí no programarem les xarxes per dins ni en farem les fórmules: les **entrenarem amb biblioteques** (scikit-learn i PyTorch) i n'**observarem** el comportament.

Qui fabrica les característiques?



Als algorismes clàssics, les característiques les prepares tu. A les xarxes neuronals, les capes ocultes les aprenen.

Ara sona abstracte. D'aquí a unes quantes diapositives ho veurem passar amb quatre punts.


DUES FAMÍLIES

En què es diferencien

	ALGORISMES CLÀSSICS	XARXES NEURONALS
Què són	Una idea per algorisme: una recta, preguntes encadenades, el marge més ample	Moltes neurones iguals i simples, connectades en capes
Característiques	Les prepara la persona: polinòmiques, transformacions, codificació	Les capes ocultes aprenen representacions noves
Entrenament	Un mètode específic per a cada algorisme; molts donen sempre el mateix resultat	Sempre la mateixa recepta: gradient descent i backpropagation. Depèn de l'atzar inicial
On brillen	Taules de dades estructurades	Imatges, so, text: dades no estructurades i abundants
Cost	Segons, en qualsevol ordinador	Sovint necessiten GPU
Explicació	Molts es poden llegir: coeficients, decision trees	Difícils d'explicar: milers o milions de pesos

Atenció: **no són sempre millors**. Amb dades tabulars, un random forest o un *gradient boosting* sovint iguala o supera una xarxa, i és molt més barat.

Regressió i classificació: dues preguntes diferents




REGRESSIÓ · EL QUE HEU FET AL 5134

Què predim un **número**: la massa, un preu, una temperatura

La recta **passa entre** els punts

L'error **a quina distància** queda cada punt

scikit-learn LinearRegression, MLPRegressor



CLASSIFICACIÓ · EL QUE FAREM EN AQUESTA UNITAT

Què predim una **classe**: l'espècie, el dígit, sí o no

La recta **separa** els punts en dos grups

L'error el punt cau **al costat equivocat**

scikit-learn Perceptron, LogisticRegression, MLPClassifier


La neurona sempre calcula la mateixa suma z . En regressió, **z ja és la resposta**; en classificació, z es converteix en una **classe** o una probabilitat. Per això la **regressió logística**, malgrat el nom, **classifica**. Aquesta unitat és de classificació (la regressió amb xarxes, al NB 1.1, secció 11.1).

PART 1

Vuitanta anys d'eufòria i d'hiverns

La història de les xarxes neuronals és la d'un problema que ningú sabia resoldre, i de la idea que el va desbloquejar.

Una línia del temps amb alts i baixos



Avui ens quedam entre 1943 i 1986. Hopfield i Kohonen són la UT7 d'aquest mòdul.

De la neurona biològica a l'artificial

BIOLOGIA

Senyals que arriben per les **dendrites**

Força de cada **sinapsi**

El **soma** suma els senyals

Es dispara si supera un **llindar**

Aprendre = reforçar sinapsis

NEURONA ARTIFICIAL

Entrades x_1, x_2, x_3


Pesos w_1, w_2, w_3

Suma ponderada

Biaix i funció d'activació

Entrenar = ajustar pesos

El cervell té uns 86.000 milions de neurones. Les xarxes artificials se n'**inspiren**, però no el simulen.



McCulloch i Pitts: una neurona que calcula

Entrades de 0 o 1. La neurona compta quantes n'hi ha d'actives i, si arriba al **llindar**, dispara.

Canviant només el llindar, la mateixa neurona fa portes lògiques diferents. I amb AND, OR i NOT es pot construir **qualsevol càlcul**.

Però no aprèn res. El llindar el tries tu. És programació clàssica amb forma de neurona: `DADES + REGLES → RESPOSTES`

x_1	x_2	AND llindar 2	OR llindar 1
0	0	0	0
0	1	0	1
1	0	0	1
1	1	1	1

Rosenblatt: el perceptró

$$z = w_1 \cdot x_1 + w_2 \cdot x_2 + b$$


$$\hat{y} = 1 \text{ si } z \geq 0, \text{ si no } 0$$

1. Una **suma ponderada** de les entrades, més el biaix. 2. Una **funció d'activació**, la funció step, que converteix z en 0 o 1. I la novetat respecte de 1943: **els pesos s'aprenen a partir d'exemples**.

Amb $w_1 = 1$, $w_2 = 1$ i $b = -1,5$, $z = x_1 + x_2 - 1,5$:


x_1, x_2	z	$z \geq 0?$	$\hat{y}$
0, 0	-1,5	no	0
0, 1	-0,5	no	0
1, 0	-0,5	no	0
1, 1	+0,5	sí	1

És la porta **AND**.



La línia negra són els punts on $z = 0$: per damunt la neurona diu 1, per davall diu 0. Els **pesos** inclinen la recta i el **biaix** la desplaça. **Entrenar un perceptró és buscar la recta** que deixa cada classe a un costat.

Amb dues entrades, la recta és un pla




La porta AND d'abans: $z = x_1 + x_2 - 1,5$. Amb **dos pesos i un biaix**, z és un **pla inclinat**: cada punt (x_1, x_2) en té l'altura.

Allà on el pla **talla el terra** ($z = 0$) hi ha la **frontera**: la recta de la diapositiva anterior. Per damunt del terra, la neurona diu 1; per davall, 0.

Amb una entrada, la frontera és un punt; amb dues, una recta; amb tres, un pla. La idea sempre és la mateixa.

Una recta i un llindar



Pensa en un examen. La **nota** és un número; **aprobat** o **suspès** és una classe. Per passar de l'un a l'altre, un **tall**: el 5.

Una neurona fa el mateix. Ho veiem amb una sola mesura, l'aleta, per distingir Adelie (0) de Gentoo (1).


1 · La recta dona un número per a cada pingüi: és una regressió lineal, com al 5134. Però -0,45 o 1,31 no són cap espècie.

2 · El tall a 0,5 el converteix en classe: $\geq 0,5 \rightarrow$ Gentoo. La frontera és un punt, **203,9 mm**, i encerta el 98,5%.

Això és una neurona: una recta (z) i una **funció d'activació**. Al perceptró, l'activació és aquest tall: la **funció step**.

La regla del perceptró

Comença amb una recta qualsevol i repassa els punts un a un. **Si encerta, no toca res.** Si s'equivoca, **acosta una mica la recta a aquell punt**, per intentar deixar-lo al costat bo. Una passada per tots els punts és una **epoch**.




La porta AND. Color del punt: la resposta correcta. Color del fons: el que diu la neurona. Encerclats en vermell, els errors.

Cada moviment és petit. **Com** de petit ho diu el **learning rate** (Perceptron($\eta=0.1$)): és el primer **hiperparàmetre**. No s'aprèn, el tries tu.

Teorema de convergència: si existeix una recta que separa les classes, el perceptró la troba en un nombre finit de passos. Fixau-vos en el «si».

Adelie o Gentoo, amb una sola neurona




274 pingüins del 5134. Dues mesures. **Encert a test: 100%.**

Però l'escala de les entrades importa. Amb les mesures en mm, el perceptró s'equivoca en gairebé la meitat dels pingüins durant les dues primeres epochs; amb les mesures escalades, ho resol a la primera.

L'aleta fa ~200 mm i el bec ~17: les correccions d'un pes són deu vegades les de l'altre. **A les xarxes neuronals, escalar no és opcional:** `StandardScaler` + perceptró en una pipeline.

El mur de la XOR



XOR val 1 quan **una i només una** entrada és 1.

Els punts taronges són a una diagonal i els blaus a l'altra: **no hi ha cap recta** que els separi. El perceptró hi pot estar epochs i epochs.

Minsky i Papert ho van analitzar al llibre *Perceptrons*. La retallada de finançament que va seguir es coneix com el **primer hivern de la IA**.

Com ho resoldria un algorisme clàssic?

x_1	x_2	$x_1 \cdot x_2$	z	$\hat{y}$	XOR
0	0	0	-0,5	0	0
0	1	0	+0,5	1	1
1	0	0	+0,5	1	1
1	1	1	-0,5	0	0

$$z = x_1 + x_2 - 2 \cdot (x_1 \cdot x_2) - 0,5$$

Però algú ha hagut de **pensar** que el producte era la columna que calia. Amb quatre punts és fàcil. Amb una foto d'un milió de píxels, quina columna inventes per saber si hi ha un gat?

Al 5134, quan una recta no basta, **fabricam una característica nova**. Aquí, la columna $x_1 \cdot x_2$: només val 1 a la fila (1, 1), just la que fa nosa.

Ara el perceptró té tres entrades i pot fer això: **compta els uns** ($x_1 + x_2$), però si n'hi ha dos, la columna nova **en resta dos**. La fila (1, 1) passa de $z = 1,5$ a $z = -0,5$ i cau al costat del 0. **Les quatre files, bé.**


I si la xarxa aprengué sola quines característiques necessita?

PART 2

La solució: afegir capes

Posar neurones entre l'entrada i la sortida. Primer ho farem a mà, per entendre per què funciona. Després, que ho aprengui sola.

Si una recta no basta, en posam dues




Els taronges són **al mig**, entre els dos blaus. Una recta talla el pla en dos trossos; per aïllar la franja del mig en calen **dues**.

RECTA	QUÈ PREGUNTA	PORTA
1	Hi ha almenys un 1? Deixa fora el (0, 0).	OR
2	Que no siguin tots dos 1? Deixa fora el (1, 1).	NAND

XOR = 1 quan les dues respostes són **sí**: el punt és dins la franja.

Cada recta és un perceptró normal, com el de l'AND. Ja sabem fer-los. Només en falta un tercer que en combini les respostes.

La XOR amb una capa oculta




Seguim les quatre files per la xarxa:

x_1	x_2	$h_1 \cdot \text{OR}$	$h_2 \cdot \text{NAND}$	AND
0	0	0	1	0
0	1	1	1	1
1	0	1	1	1
1	1	1	0	0

La sortida és exactament la XOR. Les neurones del mig no es veuen ni a l'entrada ni a la sortida: formen una **capa oculta**. Això ja és un **perceptró multicapa** (MLP).

La capa oculta transforma el problema



La neurona de sortida **no veu x_1 ni x_2** : només veu h_1 i h_2 , les columnes de la taula anterior. Si les feim servir de coordenades, **els mateixos quatre punts** canvien de lloc (cada un duu l'etiqueta de la seva entrada): els dos taronges cauen junts a (1, 1).

I dir 1 només a (1, 1) és la **porta AND** de la diapositiva 10: una recta basta. h_1 i h_2 són **característiques noves**, com $x_1 \cdot x_2$. La diferència: les fa una capa de neurones i, en una xarxa entrenada, **les tria l'entrenament**.

Per què va costar disset anys?

Saber que les capes funcionen no diu **com trobar-ne els pesos**. Hi havia dos obstacles.

1. A qui tiram la culpa?

La regla del perceptró compara la sortida amb la resposta correcta. Però una neurona oculta **no té resposta correcta**: ningú no li ha dit que havia de fer OR.

Si la xarxa s'equivoca, quina neurona oculta en té la culpa, i quanta?

2. La funció step és plana


La neurona dona 0 o 1 i res entremig. Si mous un pes una mica, la sortida continua sent la mateixa: **no canvia gens**.

Sense cap canvi, no hi ha pista de cap a on moure el pes per millorar.

La solució té tres peces: **funcions d'activació sense salts, gradient descent i backpropagation**.

Funcions d'activació sense salts

La funció step salta de cop de 0 a 1. Les altres tres fan una **corba sense salts**: si un pes canvia una mica, la sortida també canvia una mica, i això ens diu cap a on moure'l per equivocar-nos menys.



Step. Plana, amb un salt al 0: no dona cap pista. No serveix per entrenar capes.

Sigmoide. De 0 a 1, es llegeix com una probabilitat. A la sortida.

tanh. De -1 a 1, centrada. La farem servir a la capa oculta.

ReLU. L'opció per defecte de les xarxes profundes actuals.

Per al 5134: una neurona amb sigmoide és exactament una regressió logística. El que la converteix en xarxa és apilar-ne moltes.


Loss i gradient descent

La **loss** diu com de malament ho fa la xarxa. Al 5134 vau veure que dibuixa una **vall**.


Enmig de la boira, per baixar mires cap a on fa pendent i fas una passa cap avall.

$$w \leftarrow w - \text{learning_rate} \cdot \text{pendent}$$

El conjunt de pendents de tots els pesos és el **gradient**.



Backpropagation: repartir la culpa cap enrere



La sortida sap exactament quant s'ha equivocat: **predicció – resposta**. És la mateixa idea que l'error del perceptró.

Cada neurona oculta en rep una part proporcional a:

- el **pes** que la uneix amb la sortida (si el seu vot pesava molt, té molta culpa)
- el **pendent** de la seva activació (si estava saturada, poca)

4 · Amb la culpa de cada neurona, fem una passa de gradient descent a cada pes.

El bucle d'entrenament

a cada passa d'entrenament:

1. pas endavant → predicció
2. loss → com de malament
3. pas enrere → culpa de cada neurona
4. actualització → una passa avall

```
model = MLPClassifier(hidden_layer_sizes=(3,),  
                      activation="tanh")  
  
for step in range(10):  
    model.partial_fit(X, y, classes=[0, 1])  
    print(model.loss_)    # 0.643 → 0.512
```


Entrenar una xarxa és **repetir aquests quatre passos milers de vegades**.

Les xarxes que reconeixen imatges o generen text fan aquest mateix bucle, amb més capes, més neurones i més dades.

No ho programem: ho observem.

`MLPClassifier` fa els quatre passos cada vegada que entrena. Nosaltres en mirem el resultat: `loss_curve_`, `coefs_` i la frontera.


L'MLP aprèn la XOR tot sol



No li hem dit que calien portes OR i NAND ni quins pesos fan falta. Només les quatre files i les respostes.

La corba de loss és el primer gràfic que s'ha de mirar sempre: aquí cau en picat les primeres epochs i després s'aplana a prop de zero. I la frontera **ja no és una recta**: en són dues, que formen una franja.

Les dues llunes




MODEL	ENCERT A TEST
Referència (Dummy)	0,50
Regressió logística	0,86
Perceptron	0,85
MLPClassifier (8, tanh)	0,94
MLPClassifier (16, 16)	0,95


Logística i perceptró són una sola neurona: una recta. No és que siguin dolents, és que el problema no és lineal.

Neurones, learning rate i atzar


1 neurona · train 0,86 / test 0,86



2 neurones · train 0,87 / test 0,87



4 neurones · train 0,94 / test 0,93



32 neurones · train 0,99 / test 0,92



Neurones ocultes. Amb poques, la frontera no es pot corbar. Amb 32, l'entrenament puja al 0,99 i el test baixa: memoritza el soroll, l'**overfitting**.

Learning rate. Probablement el més important. Massa petit no avança; massa gran rebota o divergeix. Es diagnostica mirant la corba de loss.

La llavor aleatòria. Amb 2 neurones ocultes, la XOR s'encalla o no segons els pesos inicials: un **mínim local**. Una regressió lineal sempre dona el mateix.

MLPClassifier: cada paràmetre té sentit

```
model = MLPClassifier(  
    hidden_layer_sizes=(16, 16),  
    activation="tanh",  
    learning_rate_init=0.01,  
    batch_size=200,  
    max_iter=2000,  
    random_state=42)  
model.fit(X_train, y_train)  
model.score(X_test, y_test)  
model.loss_curve_
```

PARÀMETRE	QUÈ ÉS
hidden_layer_sizes	capes ocultes i neurones de cada una
activation	funció d'activació de les capes ocultes
learning_rate_init	learning rate
batch_size	mostres per passa (part 3)
max_iter	màxim d'epochs
random_state	llavor dels pesos inicials

La interfície és la de tots els models de scikit-learn: `fit`, `predict` i `score`. **Es pot intercanviar per una regressió logística o un random forest sense tocar la resta del codi.**

Per defecte fa servir ReLU i l'optimitzador **Adam**, una variant del gradient descent que ajusta la passa de cada pes. La recepta de fons és la mateixa: pas endavant, loss, pas enrere, actualització. Per predir un número en lloc d'una classe hi ha **MLPRegressor**, amb els mateixos paràmetres.

Dades de veritat: 70.000 dígits escrits a mà

Portem l'MLP de les llunes a MNIST. Canviar d'escala obliga a introduir tres idees noves, i ens deixa veure què aprenen de debò les neurones.

Una imatge és una fila de 784 números




28 × 28 píxels de 0 (paper) a 255 (tinta),
posats en fila: **784 columnes**.

Entrenament	50.000
Validació	10.000
Test segellat	10.000

LeCun i col·laboradors, 1998. Durant anys, *la* prova de referència de la visió per computador. A scikit-learn:

```
fetch_openml("mnist_784") .
```

De 2 classes a 10: softmax




Deu neurones de sortida, una per dígit. La **softmax** converteix les deu puntuacions en deu probabilitats que sumen 1.

La resposta es codifica en **one-hot**: deu posicions, totes a 0 menys la correcta.

MLPClassifier ho fa sol. Amb més de dues classes posa la softmax a la sortida i fa el one-hot per dins; ho diu l'atribut `out_activation_`. La backpropagation és la mateixa.

Mini-batches: moltes passes per epoch



Barrejar, partir en batches de 64 i fer **una passa per batch**.


Mateixes dades i mateixes 5 epochs. Amb batches de 64 es fan quasi 800 vegades més passes, però el temps només es multiplica per tres o quatre. A scikit-learn,

```
batch_size
```

Iteració	un batch processat i una actualització
----------	--

Epoch	totes les dades: 782 iteracions
-------	---------------------------------

Validació durant l'entrenament



Xarxa **784-128-10**: més de **100.000 pesos**. La de la XOR en tenia 13.


`MLPClassifier` amb tanh i batches de 64, entrenat epoch a epoch amb `partial_fit` : **97,65% a validació** en 20 epochs.

Al principi les dues corbes pugen juntes. Cap al final l'entrenament continua millorant i la validació s'atura: comença l'**overfitting**.

Test segellat, obert al final: **97,61%**. L'estimació de validació era fiable.


Plantilles contra traços

REGRESSIÓ LOGÍSTICA



Un model lineal aprèn **una plantilla per dígit** i hi compara cada imatge.

NEURONES OCULTES DE L'MLP



Cap no és un dígit: són **traços** en una zona. La sortida combina quins traços hi ha. **Ningú no li ha dit que busqués traços.**

Les característiques apreses serveixen

El mateix model lineal, una regressió logística, amb tres entrades diferents:

784 píxels originals

92,8%

Una frontera lineal sobre píxels no dona per més.

128 característiques **apreses** per la capa oculta

97,9%

Sis vegades menys columnes i molt més encert.

128 característiques d'una xarxa **sense entrenar**

90,9%

El control: passar per neurones no fa màgia.

És la figura de la XOR a gran escala: la capa oculta transforma les dades en una representació on un model lineal ja funciona.

Les xarxes guanyen, però per poc

MODEL	ENCERT A VALIDACIÓ
Referència (Dummy)	10,6%
Regressió logística	92,8%
Random forest (100 decision trees)	97,2%
MLP (128, tanh)	97,65%
MLP per defecte (ReLU, Adam)	97,8%

Un random forest, sense capes ocultes, queda a menys d'un punt.

EL LÍMIT: DESPLAÇAR 3 PÍXELS



Regressió logística	92,8% → 42,2%
Random forest	97,2% → 54,2%
MLP (128, tanh)	97,65% → 53,6%

Per a l'MLP la imatge és una taula: **no sap quins píxels són veïns**. Les xarxes **convolucionals** reutilitzen el mateix detector a totes les posicions, i llavors la distància es fa enorme. Són la **UT6**.

RESUM

Les sis idees que us heu d'endur

- 1 Una **neurona** fa una suma ponderada, hi suma un biaix i aplica una activació. Separa l'espai amb una recta.
- 2 El **perceptró** aprèn corregint els pesos quan s'equivoca, però només resol problemes **linealment separables**.
- 3 Les **capes ocultes** transformen les dades en una representació on el problema sí que és separable.
- 4 Per entrenar capes calen **funcions d'activació sense salts**, una **loss** i el **gradient descent**.
- 5 La **backpropagation** reparteix la culpa de l'error cap enrere per saber com moure cada pes.
- 6 Amb dades reals calen **softmax**, **mini-batches** i **validació**. La capa oculta aprèn característiques, i l'**arquitectura decideix quines** pot aprendre.

Cinc preguntes sense una única resposta

- 1 Si una regressió logística és una neurona, per què diem que les xarxes són una **família diferent**?
- 2 El 1958 es va prometre massa i va venir un hivern. Hi veieu **paral·lelismes amb avui**?
- 3 Una xarxa encerta el 98% però no s'explica; un decision tree encerta el 94% i es llegeix. Quin triaríeu per **concedir un crèdit**? I per **trobar pingüins en fotos aèries**?
- 4 La backpropagation és de 1986 i les xarxes no dominen fins al 2012. **Què faltava**?
- 5 A MNIST, un random forest gairebé iguala l'MLP. Per què, doncs, les xarxes **han guanyat en imatges**?