MP 5149 · UT6 · XARXES NEURONALS CONVOLUCIONALS I INTRODUCCIÓ A LA VISIÓ PER COMPUTADOR

La lupa que recorre la imatge

Com mira una imatge una xarxa convolucional, fins on aguanta quan la posem a prova i com fer-la servir amb les teves pròpies fotos.

EL MAPA DE LA UNITAT

Vuit sessions, sis notebooks i un classificador teu

SESSIÓ	NOTEBOOK	LA PREGUNTA
1–2	**6.1** La lupa	Per què una CNN mira millor que un MLP?
3–4	**6.2** El laboratori	Quina xarxa guanya, i quan comença a memoritzar?
5	**6.3** Crash test	Fins on aguanta? On mira? Es pot enganyar?
6	**6.4** A espatlles de gegants	I si aprofitem una xarxa que ja sap mirar?
7	**6.5** Més enllà de classificar	Com es troben objectes, com se n'ensenyen de nous i com pinta una CNN?
8	**6.6** Projecte	El teu classificador, amb les teves fotos, passa la prova?

Com treballarem

Poca explicació i moltes missions: primer **aposta**, després **experimenta** i al final **explica**.

Les xarxes no les programem: les **entenem, les fem servir i les mesurem**, com a la UT5. El bucle d'entrenament ve donat.

Amb GPU (Colab T4 o la gràfica de l'aula) les missions van més lluny. Sense GPU, totes funcionen amb una versió més petita.

UNA MICA D'HISTÒRIA

Tres xarxes que van canviar la visió per computador

1998

LeNet-5

Yann LeCun i equip

Filtres, pooling i capes finals: la mateixa recepta que farem servir. Llegia dígits de xecs bancaris, amb uns 60.000 pesos.

2012

AlexNet

Krizhevsky, Sutskever i Hinton

Guanya la competició ImageNet: un 15% d'error, amb cinc intents per imatge, contra el 26% del segon. Hi ajuden les **GPU** i 1,2 milions de fotos.

2015

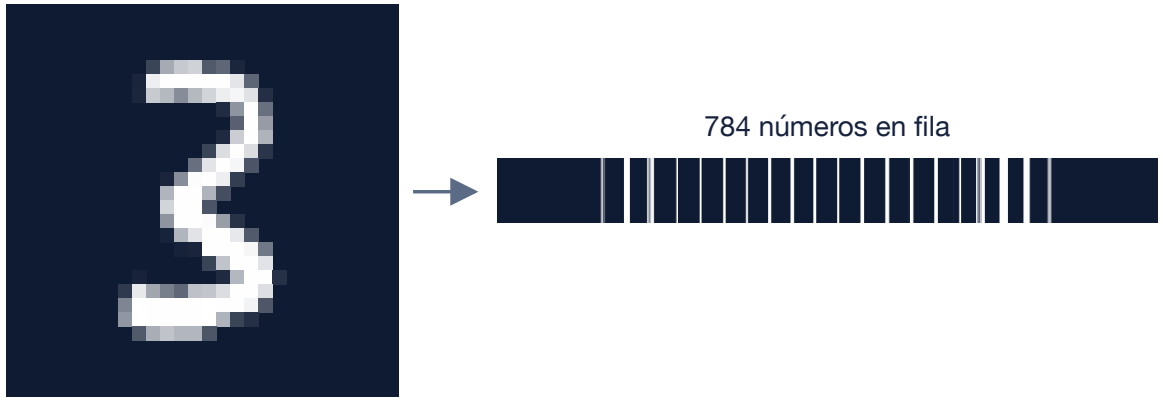
ResNet

Kaiming He i equip

Amb moltes capes, l'error costa d'arribar enrere. La solució és una **drecera**: cada bloc deixa passar l'entrada tal com és i només hi afegeix correccions.



Per a un MLP, una imatge és una fila de números



- L'MLP no sap quins píxels són **veïns**: només en veu la posició.
- Aprèn pesos per a **posicions fixes**. Si el dibuix es mou, ja no és el mateix per a ell.
- Ho vas veure al NB 1.2: amb el dígit **mogut 3 píxels** cap model no arribava al 55%, i amb **4 píxels** quedaven entre el 24% i el 36%.

Un filtre és una lupa de 3 × 3 pesos que recorre la imatge



La lupa, en una posició

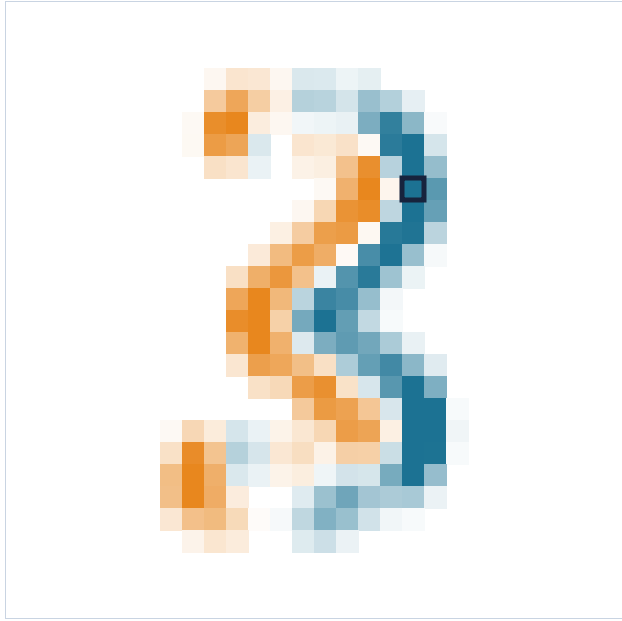
1,0	0,4	0,0	×	-1	0	1
1,0	0,6	0,0		-2	0	2
1,0	0,7	0,0		-1	0	1

Els píxels de sota · els pesos de la lupa

Multiplica casella a casella i suma:

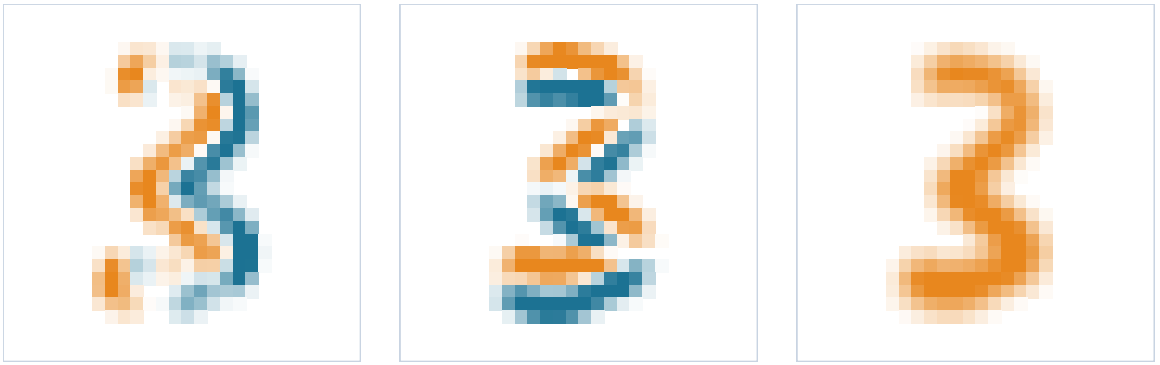
−4,0

És el número que s'escriu al mapa, en aquesta mateixa posició. Després, la lupa es mou un píxel.



El **mapa de característiques** resultant

Cada lupa busca una cosa diferent: prova-ho dibuixant



vora vertical | vora horitzontal | difuminat

Tres filtres triats a mà, amb el mateix 3. Taronja: valor positiu; blau: valor negatiu.

A animacio_lupa_cnn.html

1. Dibuixa un 3 i mira les probabilitats.
2. **Passa la lupa** i segueix com s'omple el mapa.
3. Compara els mapes triats a mà amb els que ha après la CNN.
4. Mou el dibuix: els mapes el segueixen. I la resposta?

La primera CNN: no l'escrivim, la fem servir

```
# La xarxa, amb una funció que ja ve feta
model = make_cnn(1, 10)    # 1 canal, 10 classes

# L'entrenament, amb la plantilla donada
history = train_model(model, train_loader, val_loader,
                      epochs=3, lr=0.001)
plot_history(history)
```

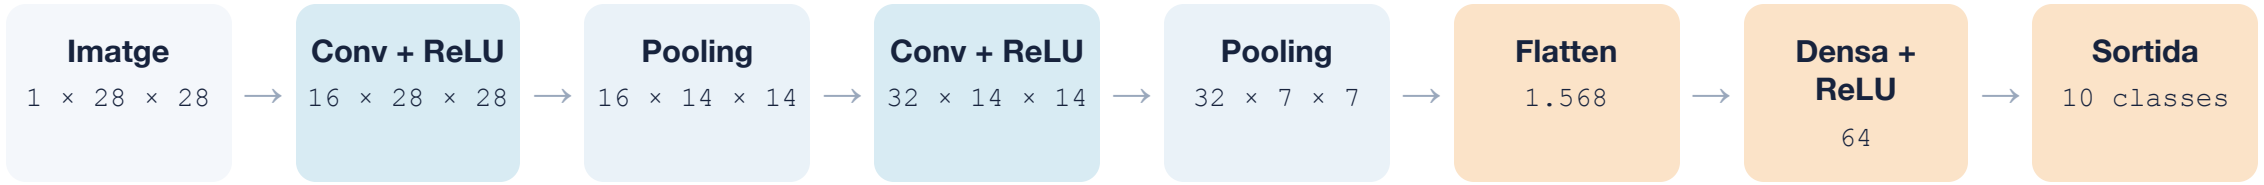
Tu en canvies l'arquitectura, els hiperparàmetres i les dades. El bucle queda comentat a la plantilla, per si el vols llegir.

	MLP (NB 1.2)	CNN
Pesos	101.770	105.866
Epochs	10	3
Encert de validació	**97,6%**	**98,5%**

Gairebé els mateixos pesos, un encert més alt i molt menys entrenament.

Ara tu · Missions 1 i 2. Aposta quin learning rate guanya abans de provar-los. Després, obre la xarxa i mira què hi ha a cada capa.

Què hi ha dins: unes capes miren i les altres decideixen



Miren: de traços a parts, cada capa més lluny

Decideixen: un MLP com el de la UT5

- La primera capa veu **traços**. La segona combina traços i veu **parts**. És el fil de la UT5: les capes ocultes aprenen les característiques.
- Cada número de sota és una mida: **quants mapes** × alt × ample.

Compartir pesos: una sola lupa per a tota la imatge

CAPA DENSA

784 entrades, 16 neurones

12.560 pesos

784 × 16 + 16 de biaix. Un pes per a cada píxel i neurona: el que aprèn en un racó no serveix per a un altre.

CAPA CONVOLUCIONAL

16 filtres de 3 × 3

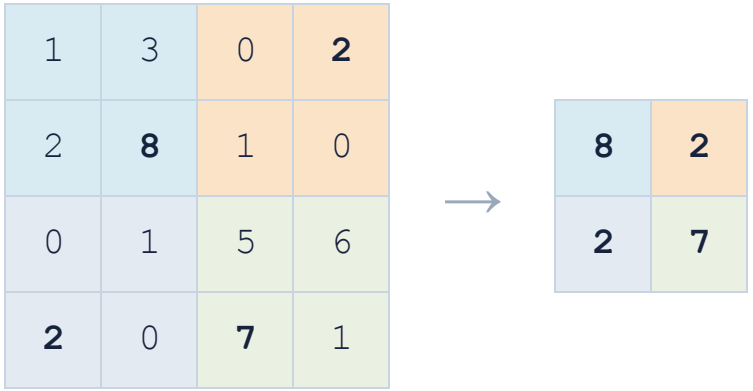
160 pesos

16 × (3 × 3 + 1 de biaix). La mateixa lupa funciona a tot arreu: si troba una vora a dalt, també la troba a baix.

A la nostra CNN, les dues capes convolucionals gasten **4.800 pesos** dels 105.866. La resta són les capes denses del final.

Ara tu · Missió 3. Fes créixer la xarxa amb `filters` i mira què guanyes, i què et costa.

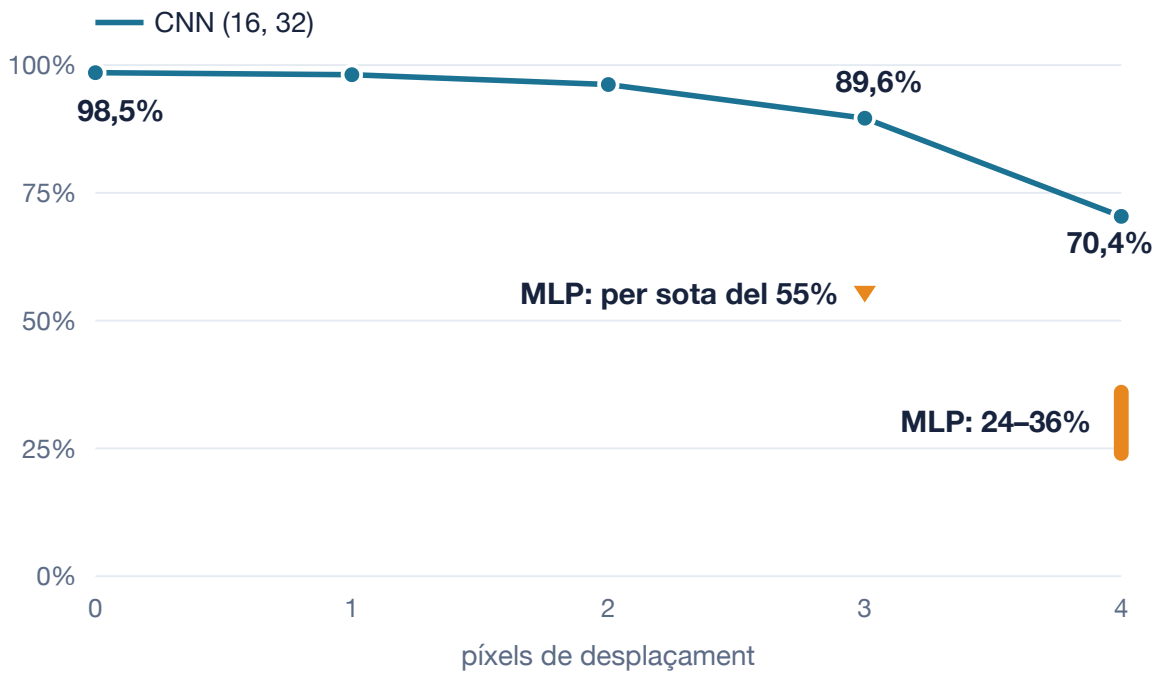
El pooling redueix sense perdre el que importa



- De cada quadrat de 2 × 2 es queda el **valor més alt**: «aquí hi havia això», sense dir on exactament.
- Cada pooling **parteix la mida per la meitat**: de 28 a 14 i de 14 a 7.
- No té pesos: no ha d'aprendre res. I les lupes de la capa següent veuen **més tros d'imatge**.

Ara tu · Missió 4. Treu el pooling amb `pooling=False`. Quants pesos hi ha ara, i quant tarda?

El moment de la veritat: el dígit desplaçat



- Aguanta molt millor que l'MLP, però **també acaba caient**.
- Les lupes segueixen el dibuix. El problema és al final: el **Flatten** posa cada mapa en fila i les capes denses tornen a mirar posicions fixes.
- Es pot arreglar? I què passaria si barregéssim els píxels?

Ara tu · Missions 5 i 6. Aposta i prova: una CNN amb `global_pool=True`, i una CNN amb tots els píxels barrejats.

El laboratori: quatre conjunts de dades, una sola funció

CONJUNT	QUÈ HI HA	MIDA	CANALS	CLASSES
MNIST	Dígits escrits a mà	28 × 28	1	10
Fashion-MNIST	Peces de roba	28 × 28	1	10
CIFAR-10	Fotos petites en color	32 × 32	3	10
Quick Draw	Dibuixos de persones	28 × 28	1	30

```
train_set, val_set, test_set, names = load_dataset("fashion")
model = make_cnn(1, 10, filters=(32, 64), batch_norm=True)
```

El llistó

Abans de cap CNN, un MLP amb Fashion-MNIST:

86,7%

d'encert en un parell de segons. **Una CNN ha de guanyar a això.** Sempre comencem per un model senzill.

Ara tu · Missions 1 i 2. Quina arquitectura traurà més encert? I si canvies Adam per SGD amb el mateix learning rate? Aposta primer.

El color: tres canals, i el problema es complica

Tres canals

Vermell, verd i blau

Cada filtre mira els tres canals alhora. Abans tenia 3 × 3 + 1 = 10 pesos; en color, en té 3 × 3 × 3 + 1 = **28**.

La mateixa xarxa que feia el 98% amb MNIST es queda en un **49,2%** amb CIFAR-10. L'atzar seria un 10%.

Batch norm

`batch_norm=True`

Reescala cada lot de valors perquè la capa següent els rebi sempre amb la mateixa escala.

VALORS	MITJANA	DESPRÉS
10, 50, 90	50	–1,2, 0, 1,2
0,1, 0,2, 0,3	0,2	–1,2, 0, 1,2

La competició: la millor xarxa amb CIFAR-10

REGLA	LLIGA CPU	LLIGA GPU
Imatges d'entrenament	**10.000**	**40.000**
Pesos	**Màxim 150.000**	**Màxim 1.000.000**
Epochs	**Màxim 5**	**Màxim 10**
Puntuació	Encert de validació de l'**última** epoch	
Què pots tocar	`filters` `pooling` `global_pool` `batch_norm` `dropout` `lr` `batch_size`	

Canvia una sola cosa cada vegada

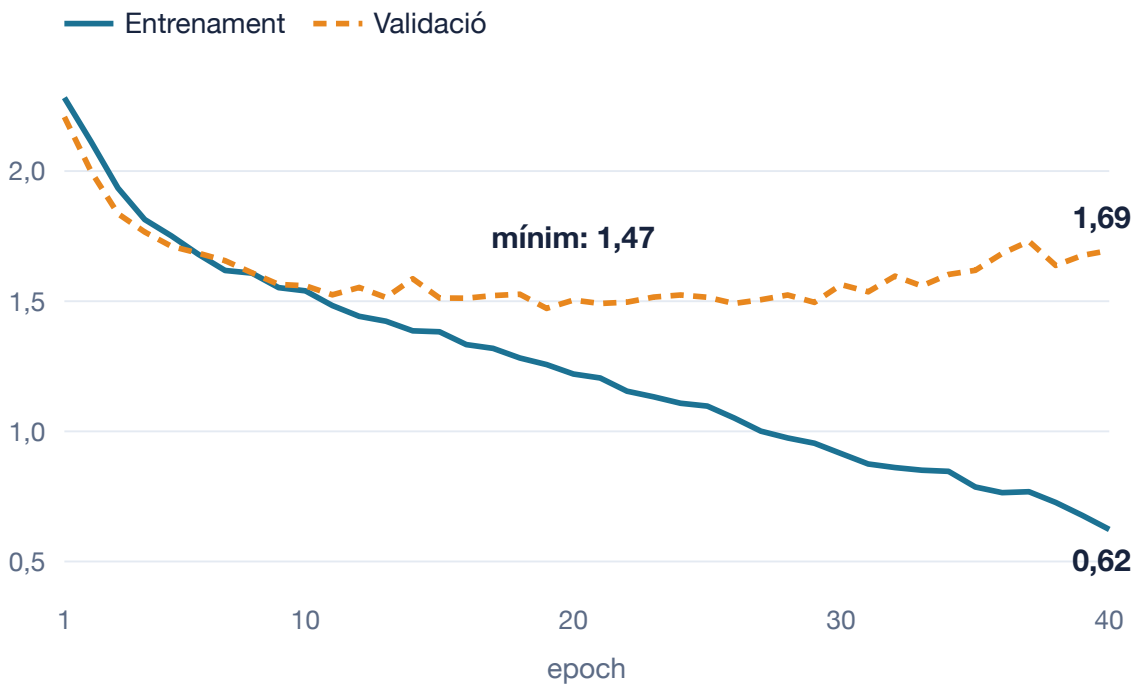
Si en canvies tres i millora, no sabràs quina ha ajudat. Apunta cada intent en una taula. Tria la lliga segons si tens GPU, i compara't només amb la teva.

I després: tu contra la xarxa

Vint imatges de CIFAR-10. Qui n'encerta més, tu o la CNN? Per què us equivoqueu en imatges diferents?

Ara tu · Missions 3 i 4. La competició i el concurs. Apunta l'aposta abans de començar.

Provocar l'overfitting: poques imatges i moltes epochs



A l'última epoch, 2.000 imatges de CIFAR-10:

80,8% a entrenament

48,4% a validació

La loss d'entrenament no para de baixar. La de validació **s'atura i torna a pujar**: la xarxa és cada vegada millor amb les imatges que ja coneix, però no amb les noves.

Dues medicines per a una xarxa que memoritza

dropout=0.5

Dropout

A cada mini-batch s'apaga a l'atzar una part de les neurones finals: de 64, en treballen unes 32, cada vegada unes altres.

Com un equip en què cada dia falta la meitat: tothom ha de saber fer una mica de tot. En validar, tornen a treballar totes.

MIRALL + DESPLAÇAMENT

Data augmentation

Cada epoch, cada imatge arriba una mica diferent. Amb 2.000 imatges i 40 epochs, la xarxa en veu 80.000, totes distintes.

```
v2.Compose([v2.RandomHorizontalFlip(),
            v2.RandomCrop(32, padding=4)])
```

Ara tu · Missió 5. Cura-la: entrena cada tractament 40 epochs i compara la distància entre entrenament i validació. Què cura millor? Què hi perds?

Pictionary: la xarxa que endevina els teus dibuixos

1. Tria unes quantes classes de **Quick Draw**: dibuixos reals fets per persones en 20 segons.
2. Entrena una CNN amb aquestes classes.
3. **Dibuixa** al llenç del notebook i mira què hi veu.

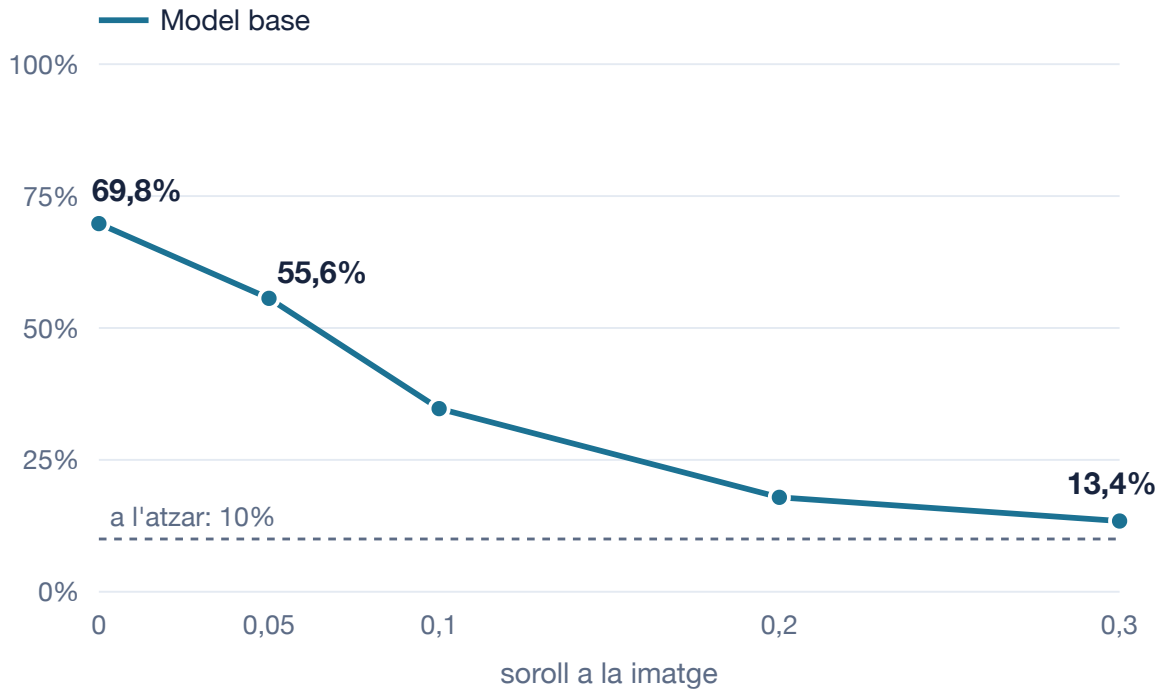
Què diu la xarxa?

La **softmax** converteix les sortides en probabilitats que sumen 100%, i `predict_top3` en mostra les tres més altes.

Un 90% no vol dir que tingui raó: si dibuixes una cosa que no coneix, l'ha de ficar igualment en alguna classe.

Ara tu · Missió 6. Juga amb la classe. Quin dibuix l'enganya més? Pots fer un dibuix dolent que encerti, i un de bo que falli?

Crash test: dos cotxes contra la paret



MATEIXA XARXA	VALIDACIÓ
Sense augmentation	69,8%
Amb augmentation	**78,4%**

90.058 pesos, 40.000 imatges i 25 epochs, ja entrenats.

Un soroll de 0,05, que a tu no et costa gens de veure a través, ja li fa perdre 14 punts. **Soroll, difuminat, gir, brillantor, un tros tapat:** cada prova és una paret diferent.

Ara tu · Missions 1 i 2. Abans de xocar: quin dels dos models aguantarà més, i a quina paret? La resposta potser no és la que esperes.

On mira? Tapa un tros i mira quant cau

QUÈ TAPEM D'UN GAT	CONFIANÇA A «GAT»	QUANT CAU
Res	80%	
Una orella	**30%**	**50 punts: mirava aquí**
Un tros del fons	78%	2 punts: no li importa

Si fem això a totes les posicions, tenim un **mapa d'oclusió**: la imatge pintada segons on la xarxa hi mirava.

Encertar per un mal motiu

Una xarxa pot dir «vaixell» perquè hi ha aigua, no pas perquè hi vegi un vaixell. L'encert no t'ho dirà: **has de mirar on mira**.

Ara tu · Missió 3. Fes de detectiu: busca un encert i un error, i descobreix on mirava en cada cas.

Enganyar-la: canvis que tu no veus

Abans
cérvol
85% de confiança

→

Després
granota
99% de confiança

Cada píxel ha canviat **poc més d'1 punt sobre 255**. Tu hi veuries la mateixa imatge.

FORÇA DE L'ATAC	PUNTS PER PÍXEL (DE 255)
0,005	Poc més d'1
0,01	Uns 2,5
0,05	Uns 13

L'atac empeny cada píxel just cap on la xarxa s'equivoca més. `attack(model, image, force)` ja ve feta: el que ens importa és **mesurar-ne l'efecte**.

Ara tu · Missions 4 i 5. Quanta força cal per fer caure cada model? I després, la fitxa de resistència del teu model del NB 6.2.

A espatlles de gegants: una xarxa que ja sap mirar

	LA TEVA CNN DEL NB 6.3	RESNET18
Pesos	90.058	11.689.512
Imatges d'entrenament	40.000	1,2 milions
Mida de la imatge	32 × 32	224 × 224

ImageNet té 1.000 classes, des de races de gos fins a instruments. Entrenar-hi una xarxa porta dies, però fer-la **servir** tarda menys d'un segon per foto.

La gata de mostra

Egyptian cat	40%
tiger cat	38%
tabby	22%

Tres mena de gat: no s'equivoca gaire. Però només coneix aquestes 1.000 classes. **I la teva mà?**

Ara tu · Missió 1. Busca què sap i què no: què diu d'una cosa que no és a ImageNet?

Transfer learning: ens quedem tot menys l'última capa

Una imatge
224 × 224

→

ResNet18, sense entrenar res
Vores, textures, corbes, parts d'objectes

→

512 números
que descriuen la imatge

→

`MLPClassifier`
com els de la UT5

- Els 512 números ja descriuen la imatge. Amb 64 neurones, l'MLP entrena **menys de 34.000 pesos** en lloc d'11 milions.
- El primer pas només es fa **una vegada**: després pots provar moltes coses gairebé sense esperar.
- Tornem a `fit` i `predict`: la xarxa grossa és una eina que prepara les característiques.

Ara tu · Missió 2. Pedra, paper o tisora: entrena'n l'última capa i compara-la amb el que treies des de zero.

Pocs exemples, la realitat i un altre món

Amb quantes imatges?

Missió 3

Entrenant des de zero amb 2.000 imatges de CIFAR-10, al NB 6.2 no passàvem gaire del 50%. I amb molt poques fotos i transfer learning? Aposta.

La teva mà

Missió 4

Fes-te fotos fent pedra, paper o tisora i prova-les. Sense cares ni res privat. Quantes n'encertarà el model? Si en falla alguna, per què?

Des de l'espai

Missió 5

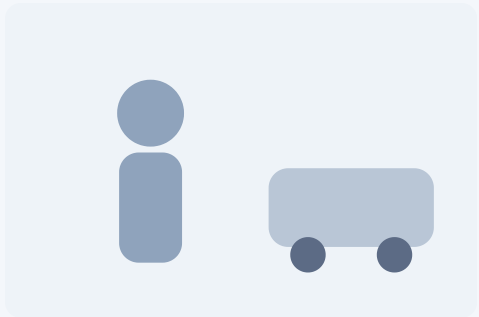
EuroSAT: fotos de satèl·lit. Una xarxa que va aprendre amb gats i tasses, pot distingir boscos de ciutats? Aposta.

Afina el gegant

Missió 6

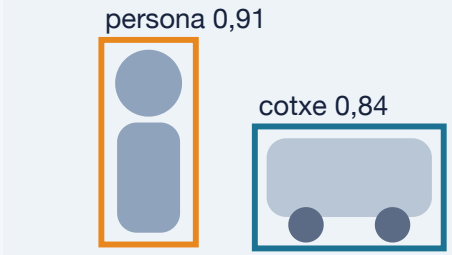
Fine-tuning: deixem aprendre també l'últim bloc de ResNet18, amb un learning rate deu vegades més petit. Millor amb GPU.

Més enllà de classificar: on és, quina forma té, com està



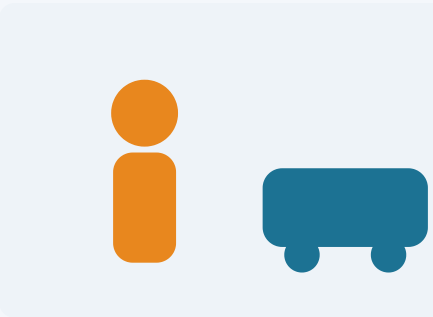
Classificar

Una etiqueta per a tota la foto: «carrer».



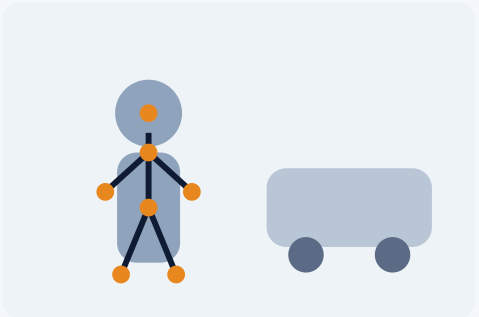
Detectar

Un requadre, una classe i una confiança per a cada objecte.



Segmentar

El contorn exacte de cada objecte, píxel a píxel.



Trobar poses

Els punts del cos de cada persona: espatlles, colzes, genolls...

Tot amb **YOLO11n**, un model ja entrenat, de la biblioteca Ultralytics. En una foto d'un carrer amb neu troba **5 semàfors, 3 persones i 2 cotxes**. En una fotografia de 1901, **8 persones** amb la seva pose.

El llindar de confiança és una decisió teva

Llindar baix

Ho troba gairebé tot, però s'inventa coses. Va bé si perdre't un objecte és greu.

Llindar alt

El que diu que hi és, gairebé segur que hi és, però se'n deixa molts. Va bé si una falsa alarma surt cara.

- `conf` indica a partir de quina confiança es mostra un objecte. Per defecte, **0,25**.
- **No hi ha un valor bo per a tot:** depèn de què costa cada error.
- Quan encara no saps què fer, passa-li el **crash test**: gira la foto, redueix-la.

Ara tu · Missions 1, 2 i 3. Aposta quants objectes hi haurà amb cada llindar, busca què no sap trobar, i posa YOLO a la paret.

Ensenya-li animals nous, i pinta com un quadre

Un detector per a la sabana

Missió 4

COCO no té rinoceronts ni búfals. Partim de YOLO11n i l'entrenem amb **1.052 fotos** d'*African Wildlife*, amb els requadres dibuixats a mà. És **transfer learning**, amb una sola línia: `train` .

Davant d'una mare rinoceront amb la cria, el detector de COCO hi veu **2 vaques**. El nou, **2 rinoceronts**. **I què ha oblidat?**

Pinta com un quadre

Missió 5

Una CNN ja entrenada, VGG19, separa el **què** d'una foto del **com**: les formes viuen a les capes profundes; els colors i les textures, a les primeres. Gatys i col·laboradors (2015) en van treure la **transferència d'estil**.

Amb `depth` tries de quantes capes es copia l'estil. **El detector encara hi veurà el gat?**

Amb GPU, el detector s'entrena en uns minuts. Sense, es carrega un model que ja hem entrenat.

Ara tu · Missions 4 i 5. Aposta què dirà el detector nou del carrer nevat, i quina capa et deixa el quadre més bonic.

El projecte: el teu classificador, amb les teves fotos

1. **Fes les fotos:** 3 o 4 classes, més de 30 per classe, amb molta varietat.
2. **Separa'n una part** per provar. Si encertes menys que l'atzar (33% amb 3 classes), hi ha un problema.
3. **Referència:** una CNN des de zero.
4. **El teu model:** ResNet18 + `MLPClassifier`. Amb GPU, també el fine-tuning.
5. **Fitxa de resistència:** soroll, difuminat, gir, brillantor i un tros tapat.
6. **Fotos noves** i una altra persona que hi posa les seves.

Regles de les fotos

Només objectes. Ni cares, ni persones, ni matrícules, ni res privat.

Com s'avaluarà

Dades, procés, interpretació i demo.

Un model que falla i que saps explicar val més que un model que encerta i no saps per què.

PER ENDUR-TE'N

El que t'has d'emportar de la UT6

1. **Una CNN mira amb lupes** de pesos que recorren la imatge. Compartir-les fa que mirar-la tota costi pocs pesos.
2. **Les capes aprenen de traços a parts.** Les característiques no les prepara la persona.
3. **Un encert alt no ho diu tot.** Cal posar el model a la paret, mirar on mira i intentar enganyar-lo.
4. **Quasi mai no es comença de zero:** amb un model ja entrenat i pocs exemples es pot arribar molt lluny.
5. **Prova sempre amb fotos que el model no ha vist mai,** i millor si les porta una altra persona.

PER AL DEBAT DE CLASSE

Cinc preguntes sense una única resposta

1. **Vigilància.** YOLO compta persones en una fotografia de 1901, i també a la càmera d'un carrer. On és la frontera entre **comptar vianants i seguir persones**? Qui ho hauria de decidir?
2. **Biaixos.** ImageNet té moltes races de gos i poc de molts llocs del món. Què li passa a un model amb **qui no surt a les seves fotos**? Com ho comprovaries abans de publicar-lo?
3. **Responsabilitat.** Un cotxe no veu una bicicleta perquè l'havien entrenat amb poca pluja. **Qui respon:** qui l'ha entrenat, qui l'ha venut, qui en conduïa?
4. **Seguretat.** Un canvi d'1 punt sobre 255 converteix un cérvol en una granota. On **no** posaries encara una xarxa, sabent això?
5. **Promeses.** Un fabricant diu que el seu model arriba al 99%. Què li preguntaries, després d'aquesta unitat?

Conceptes que surten de passada

Adam i SGD `optimizer`

Dues maneres de baixar la loss. SGD fa la mateixa passa relativa per a tots els pesos; Adam l'adapta a cada pes. Per això n'hi ha prou amb un learning rate de 0,001.

NB 6.1 §2 · NB 6.2 §3

AGPL-3.0

La llicència d'Ultralytics. Pots fer servir YOLO a classe; si el poses en un producte en xarxa, l'obliga a publicar-ne el codi o a comprar una altra llicència.

NB 6.5 §0

Batch norm `batch_norm`

Reescala els valors de cada lot perquè la capa següent els rebi sempre amb la mateixa escala. L'entrenament és més estable.

Diap. 13 · NB 6.2 §4

Canal

Cada capa d'una imatge: un en gris; tres (vermell, verd, blau) en color. És el primer número de la mida d'un tensor.

NB 6.1 §1 · NB 6.2 §4

Confiança

La probabilitat que el model dona a la seva resposta. No és la probabilitat real d'encertar: pot dir 99% i equivocar-se.

Diap. 20 · NB 6.4 §1 · NB 6.5 §1

Conjunt de validació

Imatges que no s'usen per entrenar i que serveixen per triar el model. El test es guarda per al final.

Tota la UT · 5134 UT2 i UT7

Dropout `dropout`

Apaga a l'atzar una part de les neurones finals durant l'entrenament perquè cap no es refiï de les altres.

Diap. 16 · NB 6.2 §6

EuroSAT

Conjunt de fotos de satèl·lit d'Europa classificades per ús del sòl (bosc, ciutat, riu...). Serveix per provar el transfer learning en un món diferent.

NB 6.4 §5

Fine-tuning

Reentrenar també l'últim bloc d'una xarxa ja entrenada, amb un learning rate molt petit perquè no oblidi el que sap. Amb GPU va molt més de pressa.

NB 6.4 §6, Missió 6 · NB 6.6 Pas 4 bis

Conceptes que surten de passada

Fitxer de pesos `.pt`

Desa els pesos d'un model perquè no calgui reentrenar-lo. Amb `weights_only=True` només se'n carreguen dades, sense executar codi.

NB 6.3 §1

Flatten

Posa tots els mapes en fila per poder-los passar a les capes denses. Aquí es perd la informació de la posició relativa.

Diap. 8 i 11 · NB 6.1 §6

Global average pooling `global_pool`

Resumeix cada mapa en una sola mitjana, en lloc del Flatten. Gasta menys pesos i no depèn tant d'on és l'objecte.

NB 6.1 §6, Missió 5

GPU

Un xip pensat per fer milers de multiplicacions alhora. Entrena molt més de pressa. A Colab és la T4; sense GPU, cada missió fa una versió més petita.

Diap. 2 i 3 · NB 6.1 §1 · NB 6.2 Missió 3 · NB 6.4 §6 · NB 6.5 §4 i §5

ImageNet

1,2 milions de fotos en 1.000 classes. La seva competició va impulsar les CNN, i els seus models preentrenats es fan servir a tot arreu.

Diap. 3 i 21 · NB 6.4 §1

joblib

Biblioteca per desar i carregar objectes de Python, com un `MLPClassifier` entrenat. A la UT8 servirà per a la inferència.

NB 6.6 Pas 7 · UT8

mAP50

L'encert d'un detector, de 0 a 1. Un requadre compta si és de la classe bona i se solapa almenys a la meitat amb el dibuixat a mà. Es fa la mitjana de les classes.

NB 6.5 §4

Padding `padding`

Vora que s'afegeix a una imatge. A les nostres capes manté la mida; a `RandomCrop` deixa espai per desplaçar la imatge abans de retallar-la.

NB 6.2 §6

Partició estratificada `stratify`

Reparteix cada classe en la mateixa proporció a les dues parts. Amb poques fotos evita que una classe quedi gairebé fora de la prova.

NB 6.6 Pas 2 · UT5 · 5134 UT7

Conceptes que surten de passada

Quick Draw

Milions de dibuixos fets per persones en un joc de Google. En fem servir 30 classes per jugar al Pictionary.

Diap. 12 i 17 · NB 6.2 §7

ResNet

Família de CNN amb dreceres, que permeten entrenar-ne moltes capes. ResNet18 en té 18; és la que reaprofitem.

Diap. 3 · NB 6.4

Softmax

Converteix les sortides de l'última capa en probabilitats que sumen 1. Per això la xarxa sempre dona una resposta, encara que no sàpiga res.

Diap. 17 · NB 6.2 §7

Tensor

Una taula de números amb diverses dimensions. Una imatge de MNIST és un tensor de 1 × 28 × 28, i un lot de 64 és de 64 × 1 × 28 × 28.

NB 6.1 §1

Transferència d'estil

Pintar una foto amb l'estil d'un quadre: es canvien els píxels perquè les capes profundes de VGG19 hi vegin la foto i les primeres, les textures del quadre.

Diap. 26 · NB 6.5 §5

YOLO

«You Only Look Once»: família de detectors que miren la imatge una sola vegada i per això són molt ràpids. N'usem la versió petita, YOLO11n.

Diap. 24 · NB 6.5 §1

Zero-shot `CLIP`

Classificar sense cap exemple de les classes: les escrius amb text i CLIP tria la que s'assembla més a la foto. La part que mira la imatge és un transformer, no una CNN.

NB 6.5 §6, missió extra